

# Laboratorio 2 — Análisis comparativo de códecs de audio

Compresión y Codificación · 1.er Semestre 2026

*Comparación de AAC-LC y Opus a 24, 64 y 128 kbps sobre música tonal, voz y transitorios*

## 1. Introducción y objetivos

Este laboratorio compara el desempeño de dos códecs perceptuales de audio, AAC-LC y Opus, sobre tres tipos de señal con características muy distintas: música tonal (orquesta, contenido armónico sostenido), voz (narración) y una señal rica en transitorios (percusión de drum & bass). Cada señal se codificó a tres bitrates objetivo (24, 64 y 128 kbps) y se midió la calidad de la reconstrucción contra la referencia original.

El objetivo es vincular los resultados objetivos con la teoría de las Clases 7 y 8: el modelo psicoacústico y la asignación de bits en AAC, la arquitectura híbrida SILK/CELT de Opus, y los mecanismos SBR y PS de los perfiles HE-AAC. La matriz experimental completa es de 3 señales  $\times$  2 códecs  $\times$  3 bitrates = 18 puntos de medición.

## 2. Metodología

### 2.1 Señales de referencia

Las tres señales se obtienen de forma reproducible con el script `descargar_senales.py`, que usa los ejemplos públicos de librosa: `nutcracker` (Tchaikovsky interpretado por Kevin MacLeod, CC-BY) como música tonal, `libri1` (narración de LibriVox, dominio público) como voz, y `choice` (Admiral Bob, CC-BY) como transitorios. Cada clip se recorta a 12 segundos, se pasa a mono y se re-muestrea a 48 kHz, guardándose como WAV PCM de 16 bits. Ese WAV es el ground truth de todas las mediciones.

Una limitación importante y conocida (señalada en la propia consigna): los ejemplos de librosa son originalmente de 22 050 Hz, por lo que su contenido espectral real llega como máximo a  $\approx 11$  kHz aunque el archivo esté re-muestreado a 48 kHz. Medimos el ancho de banda efectivo de cada referencia (umbral de  $-60$  dB respecto al pico):  $\approx 8,4$  kHz para la música tonal,  $\approx 7,6$  kHz para la voz y  $\approx 10,6$  kHz para los transitorios. Esto condiciona el análisis de SBR, como se discute en la sección 4.1.

### 2.2 Codificación y decodificación

El script `codificar.py` invoca `ffmpeg` mediante `subprocess`. Para AAC-LC se usó el codificador `aac` nativo de `ffmpeg` (el build disponible no incluye `libfdk_aac`, opción prevista por la consigna y que documentamos aquí); para Opus se usó `libopus`. Cada archivo comprimido (`.m4a` / `.opus`) se decodifica de vuelta a WAV para poder medir contra la referencia. Los archivos comprimidos y decodificados quedan en `salidas/codificadas` y `salidas/decodificadas` respectivamente.

### 2.3 Métricas

La consigna propone ViSQOL como métrica perceptual principal. En nuestro entorno de trabajo (Windows 10/11) `pip install visqol` falla porque no existe rueda pre-compilada, situación prevista explícitamente en la consigna (§2.0 y §2.3). Siguiendo esa indicación, usamos las métricas de respaldo y lo declaramos aquí:

- LSD (log-spectral distance): distancia media entre los espectrogramas logarítmicos de referencia y reconstrucción (STFT de 2048 puntos). Se aplica a las tres señales. Menor es mejor; no es una métrica perceptual, pero refleja bien la pérdida estructural (recorte de banda, huecos espectrales).
- STOI: inteligibilidad objetiva, solo para voz. Rango 0–1, mayor es mejor.
- PESQ (modo wide-band a 16 kHz): calidad perceptual MOS-LQO, solo para voz. Rango  $\approx 1$ –4,64, mayor es mejor. Cumple el rol que ViSQOL habría tenido para la señal de voz.

Además se midió el bitrate efectivo de cada archivo comprimido (tamaño en bits / duración) y se generó el espectrograma diferencial (referencia – reconstruida, en dB) para cada uno de los 18 casos. Antes de medir, `medir.py` alinea temporalmente referencia y reconstrucción por correlación cruzada, para compensar el retardo que introducen los códecs ( $\approx 2048$  muestras en AAC, 312–960 en Opus). En nuestros archivos el lag detectado fue 0 en todos los casos porque `ffmpeg` ya compensa el retardo del códec al decodificar, pero la verificación queda incluida en el pipeline.

## 2.4 Reproducibilidad

Todo el experimento se regenera con un solo comando: `./run.sh` en macOS/Linux o `.\run.ps1` en Windows. El script crea el entorno, descarga las señales, codifica, mide y grafica, dejando `resultados.csv` y todas las figuras listas.

### 3. Resultados

#### 3.1 Tabla de resultados

| Señal        | Códec | Bitrate obj. (kbps) | Bitrate real (kbps) | LSD (dB) | STOI  | PESQ |
|--------------|-------|---------------------|---------------------|----------|-------|------|
| music_tonal  | AAC   | 24                  | 26.4                | 2.82     | —     | —    |
| music_tonal  | AAC   | 64                  | 66.4                | 1.12     | —     | —    |
| music_tonal  | AAC   | 128                 | 130.1               | 0.53     | —     | —    |
| music_tonal  | Opus  | 24                  | 22.5                | 2.60     | —     | —    |
| music_tonal  | Opus  | 64                  | 60.1                | 1.41     | —     | —    |
| music_tonal  | Opus  | 128                 | 118.0               | 0.69     | —     | —    |
| transitorios | AAC   | 24                  | 25.4                | 4.89     | —     | —    |
| transitorios | AAC   | 64                  | 66.6                | 1.91     | —     | —    |
| transitorios | AAC   | 128                 | 126.7               | 0.90     | —     | —    |
| transitorios | Opus  | 24                  | 26.4                | 3.13     | —     | —    |
| transitorios | Opus  | 64                  | 65.6                | 1.57     | —     | —    |
| transitorios | Opus  | 128                 | 131.5               | 0.70     | —     | —    |
| voz          | AAC   | 24                  | 24.6                | 3.38     | 0.955 | 3.06 |
| voz          | AAC   | 64                  | 67.6                | 1.58     | 0.997 | 4.39 |
| voz          | AAC   | 128                 | 133.5               | 0.74     | 0.999 | 4.49 |
| voz          | Opus  | 24                  | 24.5                | 2.38     | 0.994 | 4.39 |
| voz          | Opus  | 64                  | 81.8                | 1.02     | 0.999 | 4.54 |
| voz          | Opus  | 128                 | 162.9               | 0.43     | 1.000 | 4.62 |

Tabla 1. Resultados completos (resultados.csv). STOI y PESQ solo aplican a la señal de voz.

#### 3.2 Bitrate real vs. objetivo




Figura 1. Bitrate efectivo medido contra el bitrate objetivo.

AAC (codificador nativo de ffmpeg en modo ABR) respeta el objetivo con desviaciones menores al 6 % en casi todos los casos. Opus, que trabaja en VBR restringido, se desvía más y en ambos sentidos: en la música tonal queda por debajo del objetivo (60,1 kbps reales contra 64 objetivo; 118 contra 128), mientras que en la voz lo supera con claridad a tasas altas (81,8 contra 64 y 162,9 contra 128 kbps). Es el comportamiento esperable de un VBR que asigna bits según la complejidad instantánea de la señal: gasta más donde la voz lo demanda y ahorra donde la música es predecible. La desviación máxima observada (+27 % en voz a 128 kbps) entra dentro del  $\pm 20\text{--}30\%$  típico de un VBR.

### 3.3 LSD según señal y bitrate




Figura 2. LSD vs. bitrate — música tonal.




Figura 3. LSD vs. bitrate — voz.




Figura 4. LSD vs. bitrate — transitorios.

Las tres familias de curvas son monótonas decrecientes (menos distorsión a mayor bitrate), como se esperaba. Los patrones por señal, en cambio, son distintos y son el resultado central del laboratorio: en voz y transitorios Opus domina a todos los bitrates, mientras que en música tonal AAC-LC obtiene menor LSD a 64 y 128 kbps y Opus solo gana a 24 kbps. La brecha más grande de todo el experimento es transitorios a 24 kbps: LSD de 4,89 dB para AAC contra 3,13 dB para Opus.

### 3.4 Métricas perceptuales de voz (STOI y PESQ)




Figura 5. PESQ (MOS-LQO) vs. bitrate — voz.




Figura 6. STOI vs. bitrate — voz.

A 24 kbps la diferencia es contundente: PESQ de 4,39 para Opus contra 3,07 para AAC, casi un punto y medio de MOS. En términos de la escala MOS, Opus a 24 kbps suena "muy bien, distorsiones apenas audibles" mientras que AAC queda en "aceptable, distorsiones perceptibles". STOI cuenta la misma historia desde la inteligibilidad: 0,994 contra 0,955. A 64 y 128 kbps ambos códecs superan PESQ 4,3 y STOI 0,997: zona prácticamente transparente donde la elección de códec deja de importar para voz.

### 3.5 Espectrogramas diferenciales




Figura 7. Diferencia espectral, transitorios AAC 24 kbps.




Figura 8. Diferencia espectral, transitorios Opus 24 kbps.

Los espectrogramas diferenciales explican los números. En transitorios a 24 kbps, AAC muestra una franja roja intensa (energía presente en la referencia y ausente en la reconstrucción) por encima de  $\approx 8$  kHz: el modelo psicoacústico fuerza un filtro pasabajos y sacrifica toda la banda alta para sostener la banda base. Opus, en cambio, conserva contenido hasta el límite de la fuente ( $\approx 10,6$  kHz) y reparte el error de forma más uniforme en tiempo y frecuencia. Medimos el ancho de banda efectivo de cada reconstrucción: a 24 kbps AAC recorta la música a 7,3 kHz y los transitorios a 8,2 kHz, mientras que Opus mantiene el ancho de banda completo de la fuente en las tres señales y los tres bitrates. A 64 y 128 kbps ambos códecs conservan la banda completa y las diferencias se concentran en errores de bajo nivel distribuidos.

## 4. Discusión

### 4.1 ¿Cuándo ayuda SBR (HE-AAC v1)?

SBR (Spectral Band Replication) reconstruye la banda alta ( $\approx 8$ –16 kHz) a partir de la banda base transpuesta más una envolvente lateral de pocos kbps. Su territorio natural es exactamente el problema que vimos en la Figura 7: AAC-LC a 24 kbps recortando el espectro en 7–8 kHz. Con HE-AAC v1, esa franja roja del diferencial se "rellenaría" con contenido correlacionado con la banda base, mejorando la sensación de brillo a un costo marginal de bits.

En nuestro experimento no pudimos evaluarlo empíricamente por dos razones que documentamos con honestidad: (1) el codificador aac nativo de ffmpeg no implementa los perfiles HE (requiere libfdk\_aac), y (2) nuestras fuentes librosa tienen contenido real solo hasta  $\approx 8$ –11 kHz, de modo que hay poca banda alta genuina que replicar — la nota didáctica de la consigna advierte justamente que para analizar SBR conviene una fuente de 44,1 kHz verdadera. La predicción teórica es clara de todas formas: SBR ayuda a bitrates  $\leq 32$  kbps en música con banda alta rica (platillos, brillo de cuerdas); no ayuda —e incluso puede introducir un timbre metálico— cuando la banda alta es ruido no correlacionado con la base, y es inútil a 128 kbps, donde AAC-LC ya codifica la banda completa de forma nativa.

### 4.2 ¿Cuándo introduce artefactos PS (HE-AAC v2)?

PS (Parametric Stereo) transmite un solo canal más parámetros de imagen (diferencias interaurales de nivel, fase y correlación) para reconstruir el estéreo. Al ser una descripción paramétrica y no una codificación de la señal, degrada la imagen estéreo cuando los canales están muy descorrelacionados: reverberaciones amplias, ambientes, grabaciones con micrófonos espaciados. El efecto medible sería una

correlación cruzada L/R de la reconstrucción mayor que la del original (el "ancho" se achica). Nuestro experimento usó señales mono, donde PS no aplica: en mono o estéreo muy correlacionado, PS es inocuo por construcción. La verificación empírica requeriría la pista HQ estéreo opcional de la consigna y el perfil aac\_he\_v2, no disponible en nuestro codificador.

### 4.3 ¿Cuándo gana Opus y por qué?

- Voz a baja tasa: es la victoria más clara (PESQ 4,39 vs. 3,07 a 24 kbps). Opus conmuta a SILK, un códec de predicción lineal diseñado específicamente para voz, que modela el tracto vocal en lugar de repartir bits por bandas de frecuencia. AAC-LC aplica a la voz el mismo esquema MDCT genérico que a la música, y a 24 kbps eso no alcanza.
- Transitorios: Opus gana a los tres bitrates (LSD 3,13 vs. 4,89 a 24 kbps; 0,70 vs. 0,90 a 128). Aquí trabaja CELT, cuyo tamaño de bloque corto (120–240 muestras, 2,5–5 ms a 48 kHz) confina el error de cuantización alrededor de cada ataque. AAC-LC usa bloques largos de 2048 muestras ( $\approx$  43 ms) y aunque conmuta a bloques cortos ante transitorios, la densidad de ataques del drum & bass lo obliga a operar casi siempre en el modo menos eficiente, además del pre-echo residual.
- Música tonal a tasas medias y altas: es el único terreno donde AAC-LC gana en nuestra tabla (LSD 1,12 vs. 1,41 a 64 kbps; 0,53 vs. 0,69 a 128). Para contenido armónico estacionario, el bloque largo de la MDCT de AAC da mayor resolución frecuencial y su modelo psicoacústico explota mejor el enmascaramiento tonal. Hay que matizar que a 128 kbps ambos están en zona perceptualmente transparente: la diferencia de LSD existe numéricamente pero es dudoso que un oyente la note, que es exactamente lo que la teoría predice ("empate" perceptual).
- Bitrate real: Opus además usó menos bits que el objetivo en música (60 y 118 kbps reales), o sea que su leve desventaja de LSD viene acompañada de un ahorro real de tasa; la comparación a igual gasto sería aún más pareja.

### 4.4 Otros ángulos

Latencia: Opus fue diseñado para tiempo real (2,5–20 ms algorítmicos) contra  $\approx$  60 ms o más de AAC-LC. Para el caso de uso de este laboratorio (codificación offline de archivos) es irrelevante, pero explica por qué Opus domina en WebRTC y telefonía mientras AAC domina en streaming y broadcast, donde la latencia de bloque no molesta y el ecosistema de hardware pesa más. Coste computacional: a las duraciones y tasas de este laboratorio ambos codifican los 12 s en fracciones de segundo; no observamos una diferencia práctica.

## 5. Conclusiones

- La elección de códec depende del contenido: Opus es superior para voz y material transitorio, sobre todo a tasas bajas; AAC-LC mantiene una leve ventaja en música tonal estacionaria a tasas medias.
- A 128 kbps ambos códecs alcanzan la zona transparente en las tres señales: las diferencias numéricas de LSD dejan de tener significado perceptual.
- El mecanismo dominante de degradación a 24 kbps en AAC-LC es el recorte de banda (pasabajos a 7–8 kHz), visible directamente en los espectrogramas diferenciales; es exactamente el problema que SBR fue diseñado para resolver.
- Los diferentes patrones de desviación del bitrate real (ABR de AAC ajustado al objetivo, VBR de Opus adaptativo al contenido) deben tenerse en cuenta al comparar códecs "a igual bitrate".
- Limitaciones declaradas: sin ViSQOL (no hay rueda para nuestro entorno; se usó PESQ+STOI+LSD según el plan de respaldo de la consigna), sin libfdk\_aac (SBR y PS discutidos teóricamente), y fuentes con ancho de banda efectivo de 8–11 kHz.

## 6. Referencias

- Clases 7 y 8 del curso — códecs perceptuales; AAC y Opus.
- RFC 6716: Definition of the Opus Audio Codec (Valin, Vos, Terriberry, 2012) y RFC 8251 (correcciones).
- Meltzer, S. y Moser, G. (2006). MPEG-4 HE-AAC v2 — audio coding for today's digital media world. EBU Technical Review.
- Hines, A. et al. (2015). ViSQOL: an objective speech quality model. EURASIP Journal on Audio, Speech, and Music Processing. [github.com/google/visqol](https://github.com/google/visqol).
- Rix, A. et al. (2001). PESQ — Perceptual Evaluation of Speech Quality. ITU-T P.862.
- Taal, C. et al. (2011). An algorithm for intelligibility prediction (STOI). IEEE TASLP.
- Documentación de ffmpeg: codificadores aac y libopus.
- Señales: "Dance of the Sugar Plum Fairy" — Kevin MacLeod (CC-BY); "Choice" — Admiral Bob (CC-BY); narración LibriVox "The Ashiel Mystery" (dominio público).